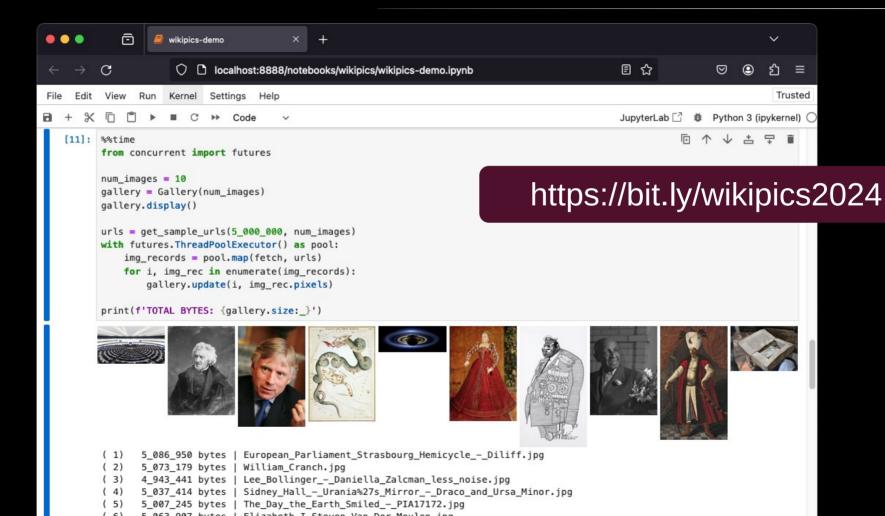
Programação concorrente em Python

Modelos de concorrência em Python

- Processos: módulos multiprocessing, futures
- Threads: módulos threading, futures
- Corrotinas: módulo asyncio
 - frameworks modernos como FastAPI

Vamos explorar os três modelos na teoria e na prática Hoje veremos threads e procesos

Demonstração: imagens da Wikipédia



Análise dos resultados

Download sequencial

```
TOTAL BYTES: 19_955_565
CPU times: user 732 ms, sys: 262 ms, total: 994 ms
Wall time: 16.4 s
```

Download com threads

```
TOTAL BYTES: 19_950_522
CPU times: user 9.27 s, sys: 251 ms, total: 9.52 s
Wall time: 2.67 s
```

Entendendo as medidas de CPU time

```
CPU times: user 732 ms, sys: 262 ms, total: 994 ms Wall time: 16.4 s
```

- **user**: tempo executando código user-mode (interpretador, seu código, bibliotecas)
- **sys**: tempo executando código kernel-mode (tudo que envolve o hardware: armazenagem, rede, tela, etc.)
- total: user + sys
- wall time: tempo transcorrido no "relógio da parede", também conhecido como "real time"

Análise: download sequencial

```
TOTAL BYTES: 19_955_565
CPU times: user 732 ms, sys: 262 ms, total: 994 ms
Wall time: 16.4 s
```

- Baixou ≈ 20 MB em 16.4 s: ≈ 1.2 MB/s
- A CPU trabalhou por 0.994 s (6% do total)
- 94% do tempo o SO executou outros processos enquanto aguardava respostas da rede
- Isso é uma tarefa I/O bound (limitada por E/S)

Análise: download com threads

```
TOTAL BYTES: 19_950_522
CPU times: user 9.27 s, sys: 251 ms, total: 9.52 s
Wall time: 2.67 s
```

- Baixou ≈ 20 MB em 2.67 s: ≈ 7.5 MB/s
 - 6.1 vezes mais rápido que sequencial (16.4 s)
- A CPU trabalhou por 9.52 s (356% do total)
 - bibliotecas usaram vários núcleos da CPU
- Melhor uso da CPU em tarefa I/O bound

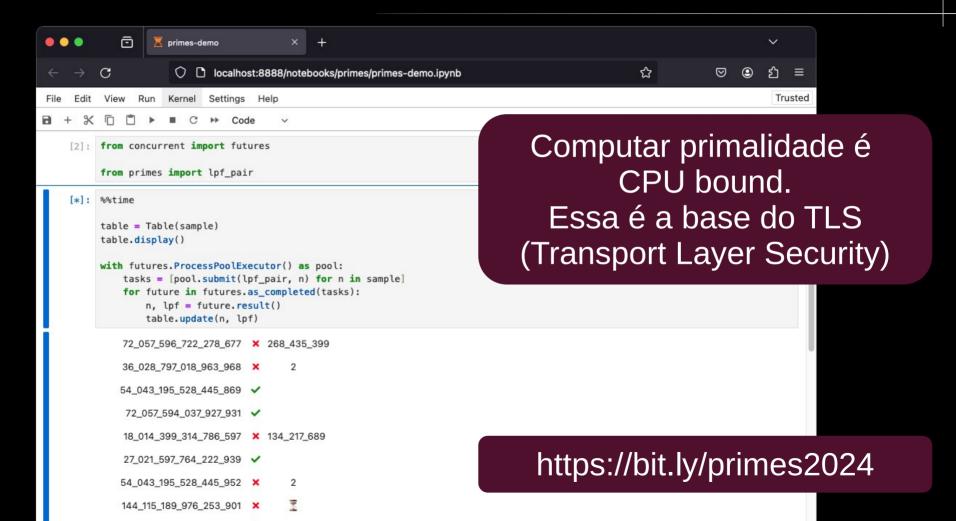
Aprendizados da demonstração

- Baixar imagem é tarefa I/O bound
 - assim como acessar arquivos, bancos de dados, APIs remotas, receber/enviar pacotes TCP/IP etc.
- Threads funcionam bem para I/O concorrente
 - Apesar da famosa GIL (Global Interpreter Lock)
 - A GIL limita todo bytecode Python a uma thread
 - Uma thread só usa um núcleo de CPU
 - O SO e certas bibliotecas escritas em C, C++, Rust, Fortran etc. não são limitadas pela GIL

Porque não usar threads sempre

- Processos, threads, e corrotinas têm característimas muito diferentes
 - Utilização de recursos: núcleos de CPU, consumo de memória, custos de inicialização
- Threads e corrotinas são eficientes para processos I/O bound
- O que acontece com CPU bound?

Demonstração: números primos



Aprendizados da demonstração

- Por causa da GIL, threads não servem para fazer processamento intensivo em CPU no código Python
 - Mas bibliotecas como Numpy são escritas em linguagens compiladas não limitadas pela GIL
 - mas depende da implementação da biblioteca

Resumo: threads x processos

	threads	processos
uso de CPU em código Python	limitado a 1 núcleo da CPU para todas as threads executando bytecode Python	cada processo pode usar um núcleo da CPU
uso de memória	memória alocada para um processo + cerca de 4MB por thread no mínimo	uso maior de memória: memória isolada para cada processo + threa ds
comunicação entre unidades de execução	todas as threads podem acessar os mesmos objetos na memória	comunicação entre processos é mais lenta e complicada
custo de inicialização	criar novo processo é caro; criar threads, nem tanto	custo maior, pois é multiplicado pelo número de processos

Concorrência x paralelismo

Concorrência x Paralelismo



Concorrência é lidar com muitas coisas ao mesmo tempo. Paralelismo é fazer muitas coisas ao mesmo tempo. Não são a mesma coisa, mas estão relacionados. Uma é sobre estrutura, outro é sobre execução. A concorrência fornece uma maneira de estruturar uma solução que pode ser paralelizada (mas não necessariamente será).

—Rob Pike, co-criador da linguagem Go

Concorrência x Paralelismo

Concorrência se faz com software. Paralelismo se faz com hardware e com programação concorrente.

—LR, autor do Python Fluente 😉



Exemplo: girando pratos

CONCURRE NCY WITH PYTHON 3.5 ASYNC & AWAIT

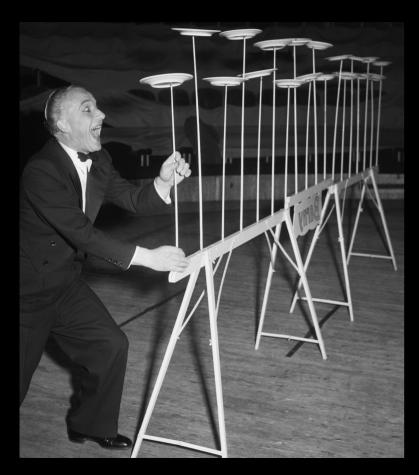


Exemplo: girando pratos

A idéia essencial da programação concorrente: não precisa ter 18 braços para girar 18 pratos.



Exemplo: girando pratos



A idéia essencial da concorrência: não precisa ter 18 braços para girar 18 pratos.

Exemplo: ps ax

```
STAT
                     TIME COMMAND
 PID
       TT
        ?? Ss
                  2:45.09 /sbin/launchd
 301
       ?? Ss
                  6:09.65 /usr/libexec/logd
 302
       ?? Ss
                  0:00.04 /usr/libexec/smd
 303
       ?? Ss
                  0:04.16 /usr/libexec/UserEventAgent (System)
                  0:01.65 /System/Library/PrivateFrameworks/Uninstall.framework/Resources/uninstalld
 305
       ?? Ss
 306
       ?? Ss
                  0:49.87 /System/Library/Frameworks/CoreServices.framework/Versions/A/Frameworks/FSEve
       ?? Ss
                  0:06.83 /System/Library/PrivateFrameworks/MediaRemote.framework/Support/mediaremoted
 307
 310
       ?? Ss
                  0:03.60 /usr/sbin/systemstats --daemon
 313
       ?? Ss
                  0:45.56 /usr/libexec/configd
 314
       ?? Ss
                  0:00.01 endpointsecurityd
                  0:20.93 /System/Library/CoreServices/powerd.bundle/powerd
 315
       ?? Ss
 316
       ?? Ss
                  0:00.01 /usr/libexec/IOMFB bics daemon
       ?? Ss
                  0:01.44 /System/Library/PrivateFrameworks/BiomeStreams.framework/Support/biomed
 317
 319
       ?? Ss
                  0:01.14 /usr/libexec/amfid
13953
       ?? S
                  0:00.02 /System/Library/PrivateFrameworks/CharacterPicker.framework/Versions/A/XPCSe
                  0:00.10 /System/Library/Frameworks/CoreServices.framework/Frameworks/Metadata.frameworks
13956
       ?? S
                  0:00.01 login -pf luciano
12893 s000 Ss
12894 s000
                  0:00.18 -zsh
                  0:00.00 ps ax
13963 s000
13055 s002 Ss+
                  0:00.02 /bin/zsh -il
```

Exemplo: ps ax

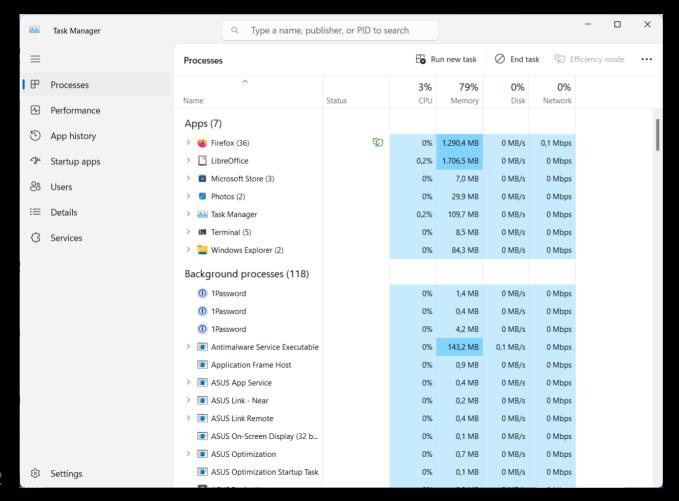
```
% ps ax | wc -l
632
% sysctl -n hw.ncpu
12
```

- 632 processos rodando no macOS Sonoma 14.1.1
- Mas a máquina tem 12 CPUs

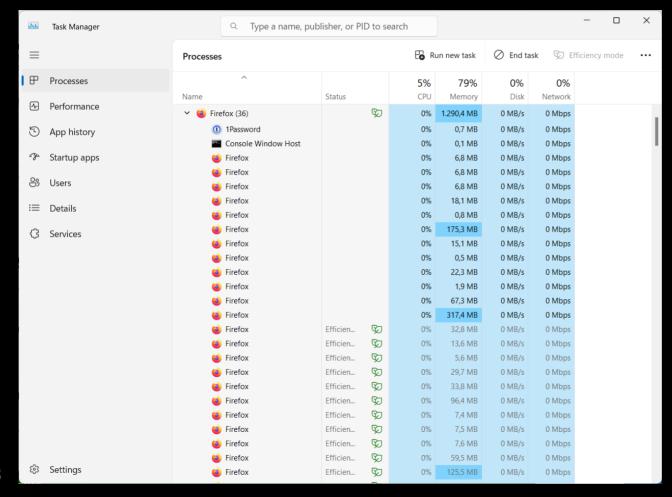
Exemplo: ps ax

```
$ ps ax | wc -l
307
$ lscpu | grep "CPU(s):"
CPU(s): 4
NUMA node0 CPU(s): 0-3
```

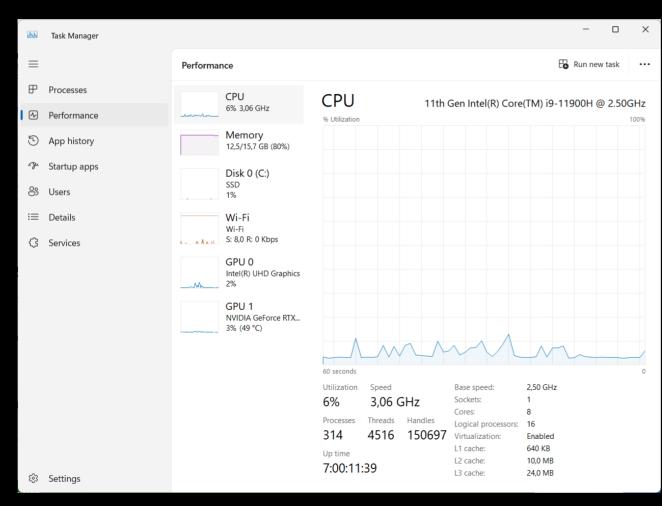
- 307 processos rodando no Ubuntu Linux 22.04
- Mas a máquina tem 4 "CPUs"
 - na real, 2 CPUs com hyperthreading

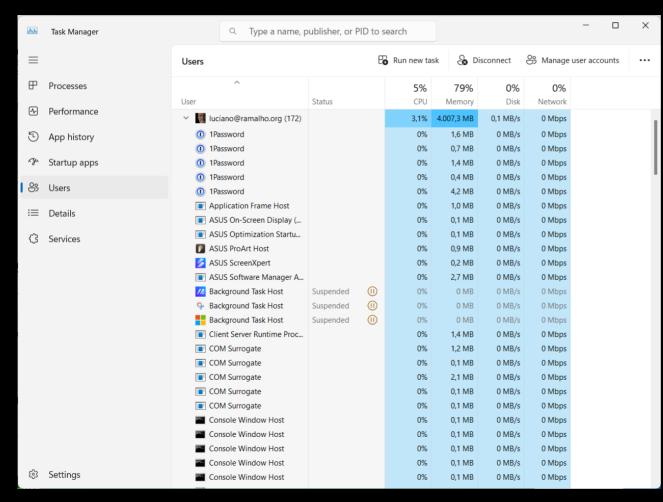


- 7 aplicativos
 - Firefox: 36 processos
- 118 processos em background
- 107 processos do Windows



- 36 processos do Firefox
 - 1Password add-on
 - Console (?)
 - Abas e janelas





Processos x threads

Processos

- Escalonamento feito pelo sistema operacional
 - SO multi-tarefa preemptivo
 - Suspende processos para dar a vez a outros
- Memória isolada pelo sistema operacional
 - Troca de dados através de pipes, sockets
 - Há mecanismos avançados para compartilhar memória, mas eles não suportam "objetos" apenas bytes

Threads

- Escalonamento feito pelo sistema operacional
 - Threads do SO em userland
 - Suspende threads para dar a vez a outras
 - No Cpython, existe a GIL (Global Interpreter Lock)
 - Só uma thread de código Python por vez
 - Extensões binárias podem executar várias threads
- Memória compartilhada
 - Suporte pleno a objetos Python

Programação assíncrona

Exemplo: Judit Pólgar*

- 20 adversários
- 1 minuto por jogada
 - Pólgar 5s, adversário 55s
- Média de 30 jogadas por partida
- 20 partidas sequenciais:
 20 × 30min = 600min = 10h



Exemplo: Judit Pólgar

- Partidas "simultâneas"
- Pólgar dá o lance inicial e vai pro próximo tabuleiro
- Uma volta completa leva $20 \times 5s = 40s$
- 20 partidas terminam em 30 × 40s = 1200s = 20min

